



Veri Madenciliği (FET445) / 2025-2026 Güz Dönemi
Dr. Yıldız Karadayı

NBA Oyuncu Performans Analizi ve Verimlilik Tahmini
(NBA Player Efficiency Analysis)

ALL-NBA

- **Apdullah Yuşa Önder 22040101029**
apdullahyusaonder@stu.topkapi.edu.tr

GitHub/Repo Link: [<https://github.com/yusaonder/verimadenciligi>]

Sunum Linki:[<https://youtu.be/1-VoybHplf4>]

1) Giriş ve Genel Bakış

Bu çalışmanın temel amacı, NBA oyuncularının sezonluk performans istatistiklerini kullanarak All-Star seçilme olasılıklarını sınıflandıran bir makine öğrenmesi modeli geliştirmektir. Bu amaç doğrultusunda veri madenciliği sürecinin tüm aşamaları — veri toplama, veri temizleme, özellik seçimi, boyut indirgeme, modelleme ve değerlendirme — sistematik biçimde uygulanacaktır. Çalışmada kullanılacak hedef değişken (All-Star seçimi), gerçek All-Star listeleri ile oyuncu-sezon eşleştirmesi yapılarak veri setine sonradan eklenmiştir. Bu durum, projenin akademik geçerliliğini artırmakta ve tahmin sürecini gerçek dünya bağlamına taşımaktadır.

2) Problem Tanımı

- **İş/Bilimsel Soru:** Bu projenin problemi, NBA oyuncularının bir sezonda ortaya koydukları performans istatistiklerine dayanarak, ilgili sezon sonunda All-Star seçilip seçilmeyeceklerini tahmin etmektir. Amaç, oyuncuların sayı, asist, ribaunt, şut yüzdeleri, top çalma, blok, maç sayısı gibi nicel performans göstergeleri ile All-Star seçilme durumu arasındaki ilişkiyi modellemek ve yeni oyuncu-sezon kayıtları için sınıflandırma yapabilen bir tahmine dayalı sistem oluşturmaktır.
- **Görev Türü:** Sınıflandırma
- **Hedef Değişken:** ALLSTAR(0=oyuncu o sezonda all star seçilmemiş 1=oyuncu o sezonda all star seçilmiş)
- **Başarı Kriterleri:** ROC-AUC $\geq 0,80$, F1 $\geq 0,75$, Precision $\geq 0,70$ ve Recall $\geq 0,70$ olarak belirlenmiştir.
- **Veri Seti Boyutu:** "Veri setimiz toplam 11.640 satır ve X sütundan oluşmaktadır."
- **Sınıf Dağılımı:** "Hedef değişkenimiz (All-Star) dengesiz bir dağılıma sahiptir: 10.944 adet 'Hayır' (%94), 696 adet 'Evet' (%6)."

3) Proje Yönetimi

- **Kilometre Taşları:**
 - **Veri Hazırlama:**
 - 1980 sonrası sezonlar filtrelendi
 - All-Star bilgisi dış kaynaktan alınarak veri setine eklendi
 - Hedef değişken AllStar oluşturuldu
 - **EDA:** Korelasyon analizi ve Eksik değer ve dağılım incelemeleri yapıldı.
 - **Modelleme:** Temel model olarak Logistic Regression KNN, Random Forest ve SVM alternatif modeller olarak denendi
 - **Değerlendirme:** ROC-AUC, F1, Precision, Recall ve Accuracy ile performans ölçüldü (Tamamlandı)
- **Roller:** Tek kişilik proje olduğu için tüm aşamalar (Veri temizleme, analiz, modelleme, raporlama) Apdullah Yuşa Önder tarafından yürütülmüştür.

4) İlgili Çalışmalar (Literatür İncelemesi)

- **Referans 1:** Hollinger, J. (2005). *Pro Basketball Forecast*. Hollinger'in geliştirdiği PER (Player Efficiency Rating), NBA analitiğinde devrim yaratmıştır. Bu projede kullanılan EFF formülü, PER'in daha basitleştirilmiş ve lineer bir versiyonudur.
- **Referans 2:** Kubatko, J. et al. (2007). *A Starting Point for Analyzing Basketball Statistics*. Bu çalışma, oyuncu verimliliğinin sadece sayı atmakla değil, top kaybı ve şut yüzdesi gibi negatif faktörlerle de dengelenmesi gerektiğini savunur. Projemizdeki EFF formülü bu negatif etkenleri (Kaçan şutlar, Top kayıpları) cezalandırarak bu yaklaşımı

destekler.


5) Veri Tanımı ve Yönetimi

- **Veri Seti:** Seasons_Stats.csv (24.691 satır - İstatistikler) ve Players.csv
- **Veri Şeması:**
 - Seasons_Stats: Year, Player, Pos, Age, Tm, G, GS, MP, FG, FGA, PTS, vb.
 - Players: Player, height, weight, collage, born.
- **Boyut:** Birleştirme ve temizleme sonrası analiz için kullanılan veri seti yaklaşık 15.000+ oyuncu-sezon kaydı içermektedir.
- **Veri Erişim Planı:** Veriler CSV formatında işlenmiş, pandas kütüphanesi ile birleştirilmiş (merge) ve temizlenmiştir.

6) Keşifsel Veri Analizi (EDA)

- **Veri Kalitesi:** Eski sezonlarda (1950-1980) eksik istatistikler (örn. 3 sayı, top çalma) olduğu için analiz 1980 sonrası "Modern Dönem" ile sınırlandırılmıştır.
- **İlişkiler:** Korelasyon matrisi incelendiğinde, EFF (Verimlilik) ile MP (Oynanan Süre), GS (İlk 5 Başlama) ve PTS (Sayı) arasında çok güçlü pozitif ilişki gözlemlenmiştir. Bu durum, çok süre alan oyuncuların daha fazla istatistik üretme şansı bulduğunu doğrulamaktadır.

Bu ısı haritası veri setindeki sayısal değişkenler arasındaki ilişkiyi (korelasyonu) göstermektedir. Kırmızıya yakın renkler güçlü pozitif ilişkiyi, maviye yakın renkler ise güçlü negatif ilişkiyi ifade eder. Hedef değişkenimiz olan EFF (Verimlilik Puanı) ile PTS (Sayı), MP (Oynanan Dakika) ve GS (İlk 5 Başlama) arasında çok yüksek pozitif korelasyon olduğu görülmüştür. Bu durum, sahada daha fazla kalan ve skora katkı yapan oyuncuların verimlilik puanlarının da yüksek olduğunu göstermektedir



7) Veri Hazırlama Planı

- **Temizleme:** Takım değiştiren oyuncuların (TOT - Total) kayıtları önceliklendirilmiş veya mükerrer kayıtlar temizlenmiştir. height ve weight sütunlarındaki eksik veriler temizlenmiştir.
- **Özellik Mühendisliği (Feature Engineering):**
 - Gerçek NBA All-Star listelerine göre oyuncu-sezon eşleştirmesi yapılarak **allstar** (0/1) hedef sütunu oluşturulmuştur.
 - Features (Özellikler): PTS (Sayı), AST (Asist), TRB (Toplam Ribaund), STL (Top Çalma) BLK (Blok) TOV (Top Kaybı) FG%, 3P%, FT% (Şut yüzdeleri) G (Maç Sayısı), MP (Dakika), Year (Dönem kontrolü için)
- **Dönüşümler:** Tüm sayısal özellikler **StandardScaler** ile ölçeklendirilmiştir. Ölçeklendirme

özellikle: **Logistic Regression** (optimizasyon kararlılığı), **PCA** (boyut indirgeme) gibi modellerde performansı artırmak için uygulanmıştır.

8) Modelleme Planı

- **Baseline Model:** Bu projede sınıflandırma için kullanılan **ilk gerçek model** Logistic Regression'dır.
- Bu projede Logistic Regression (baseline), KNN (benzerlik tabanlı), Random Forest (ensemble yöntem), ve SVM (margin tabanlı) olmak üzere dört farklı model ailesi değerlendirilmiş olup, her model All-Star seçimini farklı bir bakış açısıyla tahmin etmektedir.
- "Veri seti, modelin genelleme yeteneğini ölçmek amacıyla **%80 Eğitim (Train)** ve **%20 Test** olacak şekilde ayrılmıştır. Veri dengesiz olduğu için bölme işleminde **StratifiedKFold** veya **stratify=y** parametresi kullanılarak her iki sette de sınıf oranlarının korunması sağlanmıştır."

9) Değerlendirme Tasarımı

- **Doğrulama:** Veri seti %75 Eğitim, %25 Test olarak ayrılmıştır.
- **Metrikler:** ROC–AUC F1 Score Precision Recall Accuracy Confusion Matrix
- **Bulgular:** Bu projede hata analizi Confusion Matrix üzerinden yapılmıştır. TP ve TN değerleri modelin doğru sınıflandırma performansını yansıtırken, FN ve FP değerleri hatalı tahmin türlerini göstermektedir. Özellikle FN (gerçek All-Star'ı kaçırma) kritik bir hata türü olduğu için Recall ve F1 skorları değerlendirmede öncelikli rol oynamıştır.

10) Riskler ve Azaltma Yöntemleri

Veri Sızıntısı (Data Leakage):

- **Veri Dengesizliği:** All-Star sınıfı azınlık olduğu için model çoğunluk sınıfına kayabilir.
- **Veri Kalitesi:** Bazı sezonlarda eksik istatistikler veya çok düşük maç sayısına sahip oyuncular bulunabilir.

Overfitting: Model karmaşıklaştıkça eğitim verisine aşırı uyum sağlayıp genel performansı düşürebilir.

- **11) Kullanılan Araçlar**
- **Ortam:** Python 3.x, Jupyter Notebook.
- **Kütüphaneler:** Pandas, NumPy, Sklearn, Matplotlib, Seaborn.


Beklenen Sonuçlar ve Görselleştirme Planı,

Accuracy : 0.9582
Precision: 0.6357
Recall : 0.7069
F1-score : 0.6694
ROC-AUC : 0.9744

Bu projede kullanılan metrik tablosu, modelin All-Star tahmin performansını özetleyen temel başarı ölçütlerini gösterir. Accuracy modelin genel doğruluğunu, precision modelin "All-Star" dediği oyuncuların ne kadarının gerçekten All-Star olduğunu, recall ise gerçek All-Star oyuncuların ne kadarını tespit edebildiğini ifade eder. F1 skoru precision ve recall arasındaki dengeyi


temsil ederken, ROC-AUC modelin pozitif sınıfı ayırt etme gücünü gösterir ve yüksek değer, güçlü bir ayrıştırma performansına işaret eder.

11)Confusion Matrisi



Karışıklık matrisi modelin hangi sınıfları doğru veya yanlış tahmin ettiğini görselleştirir. Doğru tahmin edilen All-Star olmayan oyuncular ve doğru tahmin edilen All-Star oyuncular matrisin ana başarı bölgesini oluşturur. Yanlış pozitifler modelin gerçekte All-Star olmayan bir oyuncuyu All-Star olarak tahmin ettiği durumları, yanlış negatifler ise modelin gerçek All-Star oyuncuları kaçırdığı durumları temsil eder. Veri dengesizliği nedeniyle yanlış negatiflerin görülmesi olağandır.

12)ROC Eğrisi



ROC eğrisi modelin farklı eşikler altındaki performansını gösterir. Eğrinin sol üst köşeye yakın olması modelin güçlü olduğunu, yüksek AUC değerinin ise All-Star olan ve olmayan oyuncuları oldukça başarılı bir şekilde ayırabildiğini ortaya koyar. Bu grafik modelin genel sınıflandırma yeteneğinin kalitesini gösteren en önemli kanıtlardan biridir.

13)Sonuç (Conclusion)

Bu çalışmada, NBA oyuncularının sezonluk performans istatistiklerine dayanarak All-Star seçilme olasılığını tahmin etmeye yönelik bir sınıflandırma modeli geliştirilmiş ve Logistic Regression başta olmak üzere farklı model ailelerinin karşılaştırılmasıyla en başarılı yaklaşım belirlenmiştir. Uygulanan veri hazırlama, ölçeklendirme, özellik seçimi ve model değerlendirme adımları sonucunda, modellerin All-Star sınıfını ayırt etme performansı ROC- AUC ve F1 skorları üzerinden analiz edilmiş; elde edilen sonuçlar performans istatistiklerinin All-Star

seiminde gl belirlayiciler olduėunu gstermiřtir. Bu proje, spor analitiėi alanında veri madenciliėi ve makine ėrenmesi yntemlerinin etkili biimde uygulanabileceėini ortaya koyarak bařarılı bir tahmine dayalı modelleme rneėi sunmuřtur.

14) Geliřmiř Model Mimarileri ve Derinlemesine Performans Analizi

Bu alıřmanın ileri ařamasında, vize dneminde kurulan temel (base) makine ėrenmesi modellerinin tesine geilerek, literatrde "State-of-the-Art" (SOTA) olarak kabul edilen topluluk ėrenmesi (ensemble learning) ve derin ėrenme (deep learning) mimarileri projeye entegre edilmiřtir. Ama, sadece doėruluk oranını artırmak deėil, aynı zamanda veri setindeki dengesizlik problemini ynetmek ve modelin karar verme mekanizmasını optimize etmektir.


14.1) Veri Dengesizliėi Problemi ve zm Stratejisi (SMOTE)

Gerek dnya veri setlerinin doėası gereėi karřılařılan en byk zorluklardan biri sınıf dengesizliėidir (class imbalance). Proje kapsamında kullanılan NBA veri seti analiz edildiėinde, hedef deėiřken olan "All-Star" sınıfının (Sınıf 1), toplam veri setinin yalnızca yaklaşık **%6'sını** oluřturduėu, geri kalan **%94'lk** kısmın ise All-Star seilmeyen oyuncuların (Sınıf 0) meydana geldiėi grlmřtir.

Standart makine ėrenmesi algoritmaları, doėası gereėi oėunluk sınıfına (majority class) odaklanma eėilimindedir. Bu durum, modelin %94 doėrulukla alıřsa bile aslında hibir All-Star oyuncusunu tespit edemediėi (Zero Recall) yanıltıcı bir "szde bařarı" durumuna yol aabilir.

Bu yapısal sorunu gidermek amacıyla eėitim setine **SMOTE (Synthetic Minority Over-sampling Technique)** algoritması uygulanmıřtır:

- alıřma Prensibi:** SMOTE, azınlık sınıfındaki rnekleri basite kopyalamak (random oversampling) yerine, zellik uzayında (feature space) birbirine yakın olan azınlık rneklerini analiz eder. Bu rnekler arasına sanal izgiler ekerek bu izgiler zerinde yeni, sentetik veri noktaları retir.
- Uygulama Yntemi:** Veri sızıntısını (data leakage) nlemek amacıyla SMOTE iřlemi **sadece eėitim (training)** setine uygulanmıřtır. Test seti, gerek hayat senaryosunu simle etmek amacıyla orijinal ve dengesiz haliyle bırakılmıřtır.
- Sonuç:** Eėitim setindeki sınıf daėılımı %50-%50 oranında dengelenmiř, bylece modellerin "All-Star" sınıfını ėrenme kapasitesi matematiksel olarak artırılmıřtır.



(řekil 14.1: Eėitim veri setinin SMOTE iřlemi ncesi (Sol) ve sonrası (Saė) sınıf daėılımı. Veri setinin dengelenmesi, modelin azınlık sınıfına karřı duyarlılıėını artırmıřtır.)

14.2) Kullanılan İleri Seviye Model Mimarileri

Projenin bu ařamasında, her biri farklı matematiksel temellere dayanan  geliřmiř mimari kullanılmıřtır:

1. XGBoost (Extreme Gradient Boosting):

Karar ağaçlarını (decision trees) temel alan ve Kaggle gibi veri bilimi yarışmalarında standart haline gelmiş bir topluluk öğrenme algoritmasıdır.

- **Teknik Detay:** XGBoost, "Gradient Boosting" prensibiyle çalışır. Her yeni ağaç, bir önceki ağacın yaptığı tahmin hatalarını (residuals) hedef alarak eğitilir. Yani model, sıfırdan öğrenmek yerine "hatalarını düzelterek" ilerler.
- **Optimizasyon:** Projemizde GridSearchCV kullanılarak hiperparametre optimizasyonu yapılmıştır. Aşırı öğrenmeyi (overfitting) engellemek için ağaç derinliği (max_depth=5) sınırlandırılmış ve öğrenme oranı (learning_rate=0.05) optimize edilmiştir.
- **Neden Seçildi?** Yapılandırılmış (tabular) verilerde en yüksek performansı göstermesi ve eksik veriler ile aykırı değerlere karşı dirençli olması nedeniyle tercih edilmiştir.

2. TabNet (Attentive Interpretable Tabular Learning):

Google Cloud AI araştırmacıları tarafından geliştirilen TabNet, derin öğrenme (Deep Learning) mimarilerinin gücünü tabular verilere taşıyan hibrit bir modeldir.


- **Teknik Detay:** TabNet, karar ağaçlarının "özellik seçimi" (feature selection) yeteneğini, sinir ağlarının "öğrenme kapasitesi" ile birleştirir. "**Sequential Attention**" (Ardışık Dikkat) mekanizması sayesinde, model her adımda verinin hangi özelliklerine (örneğin; sadece Sayı ve Asist ortalamalarına) odaklanması gerektiğini kendi kendine öğrenir.
- **Yapılandırma:** Model, 16 nöronluk karar (decision) ve dikkat (attention) katmanları (n_d=16, n_a=16) ile yapılandırılmış, 200 epoch boyunca eğitilmiştir.

3. FT-Transformer (Feature Tokenizer Transformer):

Doğal Dil İşleme (NLP) alanında devrim yaratan Transformer mimarisinin (BERT, GPT) sayısal verilere uyarlanmış versiyonudur.

- **Teknik Detay:** Bu model, her bir sayısal özelliği (Feature) bir kelime gibi düşünerek vektör uzayına (Embedding) taşır. Ardından "Self-Attention" katmanları ile özellikler arasındaki karmaşık ve lineer olmayan ilişkileri (örneğin; bir oyuncunun boyu ile blok sayısı arasındaki ilişkiyi) öğrenir.
- **Önemi:** Özellikle SMOTE ile birleştirildiğinde, FT-Transformer azınlık sınıfını yakalamada (Recall) projenin en başarılı modeli olmuştur.

Confusion Matrisleri



Karmaşıklık matrisleri incelendiğinde; **XGBoost** modelinin 'Yanlış Pozitif' (False Positive) sayısını 32'de tutarak en temiz tahminleri yaptığı, buna karşın **FT-Transformer** modelinin 118 adet 'Doğru Pozitif' (True Positive) ile en yüksek yakalama kapasitesine sahip olduğu görülmektedir."

14.3) Deneysel Sonuçlar ve Karşılaştırmalı Analiz


Geliştirilen modellerin performansı; Accuracy (Doğruluk), Precision (Kesinlik), Recall (Duyarlılık), F1-Score ve ROC-AUC metrikleri üzerinden, orijinal (dengesiz) test seti üzerinde değerlendirilmiştir.

Tablo 14.1: Modellerin Test Seti Üzerindeki Performans Karşılaştırması

Model Mimarisi	Accuracy	Precision	Recall	F1-Score	ROC-AUC
XGBoost (Ensemble)	0.962	0.722	0.595	0.652	0.972
TabNet (Deep Learning)	0.962	0.702	0.642	0.671	0.971
FT-Transformer (SMOTE)	0.933	0.469	0.841	0.602	0.971
Lojistik Regresyon (Base)	0.958	0.635	0.550	0.640	0.960

Tablo 14.1 incelendiğinde şu kritik bulgulara ulaşılmıştır:

- Genel Doğruluk:** XGBoost ve TabNet, %96.2'lik doğruluk oranıyla en kararlı modeller olmuştur.
- Recall (Yakalama) Başarısı:** FT-Transformer modeli, SMOTE desteğiyle birlikte **%84.1** Recall skoruna ulaşmıştır. Bu, modelin gerçek All-Star oyuncularının %84'ünü doğru tespit ettiğini göstermektedir ki bu, diğer modellerden (örn. Base model %55) çok daha üstündür.




(Şekil 14.2: Gelişmiş modellerin performans metriklerine göre karşılaştırmalı analizi. FT-Transformer'ın Recall başarısı ile XGBoost'un Precision başarısı arasındaki denge açıkça görülmektedir.)

14.4) Sınıf Bazlı Ayırıştırma ve ROC Eğrileri

Sınıflandırma problemlerinde modelin başarısını sadece tek bir sayı ile ölçmek yanıltıcı olabilir. Bu nedenle modellerin "ayır etme gücü", ROC (Receiver Operating Characteristic) eğrileri ile analiz edilmiştir.

ROC eğrisi, modelin Doğru Pozitif Oranı (True Positive Rate) ile Yanlış Pozitif Oranı (False Positive Rate) arasındaki dengeyi gösterir. Eğri ne kadar sol üst köşeye yakınsa, model o kadar başarılıdır.



(Şekil 14.3: Modellerin ROC Eğrileri. Tüm gelişmiş modellerin 0.97 seviyesindeki AUC skorları, rastgele tahminden (0.5) çok uzak, yüksek güvenilirlikli tahminler yaptıklarını kanıtlamaktadır.)

Analiz Sonuçları:

- **XGBoost:** Eğrinin en dik yükseldiği modeldir, bu da yanlış alarm vermeden (düşük False Positive) yüksek başarı sağladığını gösterir.
- **FT-Transformer:** Eğri, yüksek yakalama oranı nedeniyle geniş bir alanı kapsamaktadır ancak Precision düşüklüğü nedeniyle başlangıç noktası daha yatayıdır.

Modellerin Sınıf Bazlı (Class-wise) Performans Ayrımı Tablosu

Model	Sınıf	Precision (Kesinlik)	Recall (Duyarlılık)	F1-Score
XGBoost (Ensemble)	0 (Negatif)	0.98	0.99	0.98
	1 (Pozitif)	0.72	0.60	0.65
TabNet (Deep Learning)	0 (Negatif)	0.98	0.98	0.98
	1 (Pozitif)	0.70	0.64	0.67
FT-Transformer (SMOTE)	0 (Negatif)	0.99	0.94	0.96
	1 (Pozitif)	0.47	0.84	0.60
Lojistik Regresyon (Base)	0 (Negatif)	0.97	0.98	0.97
	1 (Pozitif)	0.64	0.55	0.59

Tablo incelendiğinde; çoğunluk sınıfı olan Sınıf 0'da tüm modellerin %98 civarında başarı gösterdiği görülmektedir. Ancak asıl kritik olan Sınıf 1 (All-Star) performansıdır. **FT-Transformer**, %84 Recall oranıyla All-Star oyuncularını tespit etmede en agresif ve başarılı model olurken, **XGBoost** %72 Precision ile tahminlerinde en az yanlış (en güvenilir) model olmuştur."

14.5) Sonuç ve Nihai Model Seçimi

Bu projede, NBA oyuncularının performans verileri üzerinden All-Star seçilme durumlarını tahmin eden kapsamlı bir veri madenciliği süreci yürütülmüştür. Yapılan deneyler sonucunda iki farklı senaryo için iki farklı model önerilmektedir:

1. Senaryo A: Dengeli ve Güvenilir Tahmin (Önerilen Model: XGBoost)

Eğer amaç, yanlış tahminleri (All-Star olmayan birine All-Star demek) minimize etmek ve genel doğruluğu en üst düzeye çıkarmaksa, **XGBoost** en uygun modeldir. %96.2 doğruluk ve 0.72 Precision skoru ile en az hatayı yapan modeldir.

2. Senaryo B: Yetenek Keşfi ve Kaçırmama (Alternatif Model: FT-Transformer)

Eğer bir yetenek avcısı (scout) gözüyle bakılıp "Hiçbir potansiyel All-Star'ı gözden kaçırmamak" hedefleniyorsa, **FT-Transformer** tercih edilmelidir. %84 Recall oranı ile aday havuzunu geniş tutarak potansiyel yıldızları tespit etmede üstündür.

Sonuç olarak, bu proje modern veri madenciliği tekniklerinin (SMOTE, Ensemble Learning, Deep Learning) spor analitiğinde ne kadar etkili olabileceğini kanıtlamış ve statik istatistiklerin ötesine geçerek tahmine dayalı (predictive) bir modelleme sunmuştur.

15)Referanslar

[Veri Seti] O. Goldstein, "NBA Players stats since 1950," *Kaggle*, 2017. [Çevrimiçi]. Erişim: <https://www.kaggle.com/datasets/drgilermo/nba-players-stats>. [Erişim Tarihi: 24-Kas-2025].

[Makine Öğrenmesi Kütüphanesi - Scikit-learn] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, cilt 12, ss. 2825–2830, 2011. [Çevrimiçi]. Erişim: <https://scikit-learn.org/stable/>.

[Veri Analizi Kütüphanesi - Pandas] W. McKinney, "Data Structures for Statistical Computing in Python," *Proceedings of the 9th Python in Science Conference*, ss. 56–61, 2010.

[Basketbol Analitiği ve Verimlilik] J. Hollinger, *Pro Basketball Forecast: 2005-06*. Potomac Books, 2005. (PER ve Verimlilik hesaplamaları için temel kaynak).

[Görselleştirme - Matplotlib] J. D. Hunter, "Matplotlib: A 2D Graphics Environment," *Computing in Science & Engineering*, cilt 9, no. 3, ss. 90–95, 2007.

Basketball-Reference, "NBA All-Star Players & Seasons," *Sports Reference LLC*, 2025. Available: <https://www.basketball-reference.com/>