



Veri Madenciliđi (FET445) / 2025-2026 Güz Dönemi
Dr. Yıldız Karadayı

NBA Oyuncu Performans Analizi ve Verimlilik
Tahmini (NBA Player Efficiency Analysis)

ALL-NBA

- **Apdullah Yuşa Önder 22040101029**
apdullahyusaonder@stu.topkapi.edu.tr

GitHub/Repo Link:

[<https://github.com/yusaonder/verimadenciligi>]]

1)Giriş ve Genel Bakış

Bu çalışmanın temel amacı, NBA oyuncularının sezonluk performans istatistiklerini kullanarak All-Star seçilme olasılıklarını sınıflandıran bir makine öğrenmesi modeli geliştirmektir. Bu amaç doğrultusunda veri madenciliği sürecinin tüm aşamaları — veri toplama, veri temizleme, özellik seçimi, boyut indirgeme, modelleme ve değerlendirme — sistematik biçimde uygulanacaktır. Çalışmada kullanılacak hedef değişken (All-Star seçimi), gerçek All-Star listeleri ile oyuncu-sezon eşleştirmesi yapılarak veri setine sonradan eklenmiştir. Bu durum, projenin akademik geçerliliğini artırmakta ve tahmin sürecini gerçek dünya bağlamına taşımaktadır.

2) Problem Tanımı

- **İş/Bilimsel Soru:** Bu projenin problemi, NBA oyuncularının bir sezonda ortaya koydukları performans istatistiklerine dayanarak, ilgili sezon sonunda All-Star seçilip seçilmeyeceklerini tahmin etmektir. Amaç, oyuncuların sayı, asist, ribaunt, şut yüzdeleri, top çalma, blok, maç sayısı gibi nicel performans göstergeleri ile All-Star seçilme durumu arasındaki ilişkiyi modellemek ve yeni oyuncu-sezon kayıtları için sınıflandırma yapabilen bir tahmine dayalı sistem oluşturmaktır.
- **Görev Türü:** Sınıflandırma
- **Hedef Değişken:** ALLSTAR(0=oyuncu o sezonda all star seçilmemiş 1=oyuncu o sezonda all star seçilmiş)
- **Başarı Kriterleri:** ROC-AUC $\geq 0,80$, F1 $\geq 0,75$, Precision $\geq 0,70$ ve Recall $\geq 0,70$ olarak belirlenmiştir.

3) Proje Yönetimi

- **Kilometre Taşları:**
 - **Veri Hazırlama:**
 - 1980 sonrası sezonlar filtrelendi
 - All-Star bilgisi dış kaynaktan alınarak veri setine eklendi
 - Hedef değişken AllStar oluşturuldu
 - **EDA:** Korelasyon analizi ve Eksik değer ve dağılım incelemeleri yapıldı.
 - **Modelleme:** Temel model olarak Logistic Regression KNN, Random Forest ve SVM alternatif modeller olarak denendi
 - **Değerlendirme:** ROC-AUC, F1, Precision, Recall ve Accuracy ile performans ölçüldü (Tamamlandı)
- **Roller:** Tek kişilik proje olduğu için tüm aşamalar (Veri temizleme, analiz, modelleme, raporlama) Apdullah Yuşa Önder tarafından yürütülmüştür.

4) İlgili Çalışmalar (Literatür İncelemesi)

- **Referans 1:** *Hollinger, J. (2005). Pro Basketball Forecast.* Hollinger'in geliştirdiği PER (Player Efficiency Rating), NBA analitiğinde devrim yaratmıştır. Bu projede kullanılan **EFF** formülü, PER'in daha basitleştirilmiş ve lineer bir versiyonudur.
- **Referans 2:** *Kubatko, J. et al. (2007). A Starting Point for Analyzing Basketball Statistics.* Bu çalışma, oyuncu verimliliğinin sadece sayı atmakla değil, top kaybı ve şut yüzdesi gibi negatif faktörlerle de dengelenmesi gerektiğini savunur. Projemizdeki **EFF** formülü bu negatif etkenleri (Kaçan şutlar, Top kayıpları) cezalandırarak bu yaklaşımı destekler.


5) Veri Tanımı ve Yönetimi

- **Veri Seti:** **Seasons_Stats.csv** (24.691 satır - İstatistikler) ve **Players.csv**
- **Veri Şeması:**
 - **Seasons_Stats:** Year, Player, Pos, Age, Tm, G, GS, MP, FG, FGA, PTS, vb.
 - **Players:** Player, height, weight, collage, born.
- **Boyut:** Birleştirme ve temizleme sonrası analiz için kullanılan veri seti yaklaşık 15.000+ oyuncu-sezon kaydı içermektedir.
- **Veri Erişim Planı:** Veriler CSV formatında işlenmiş, **pandas** kütüphanesi ile birleştirilmiş (**merge**) ve temizlenmiştir.

6) Keşifsel Veri Analizi (EDA)

- **Veri Kalitesi:** Eski sezonlarda (1950-1980) eksik istatistikler (örn. 3 sayı, top çalma) olduğu için analiz 1980 sonrası "Modern Dönem" ile sınırlandırılmıştır.
- **İlişkiler:** Korelasyon matrisi incelendiğinde, **EFF** (Verimlilik) ile **MP** (Oynanan Süre), **GS** (İlk 5 Başlama) ve **PTS** (Sayı) arasında çok güçlü pozitif ilişki gözlemlenmiştir. Bu durum, çok süre alan oyuncuların daha fazla istatistik üretme şansı bulduğunu doğrulamaktadır.

Bu ısı haritası veri setindeki sayısal değişkenler arasındaki ilişkiyi (korelasyonu) göstermektedir. Kırmızıya yakın renkler güçlü pozitif ilişkiyi, maviye yakın renkler ise güçlü negatif ilişkiyi ifade eder. Hedef değişkenimiz olan **EFF** (Verimlilik Puanı) ile **PTS** (Sayı), **MP** (Oynanan Dakika) ve **GS** (İlk 5 Başlama) arasında çok yüksek pozitif korelasyon olduğu görülmüştür. Bu durum, sahada daha fazla kalan ve skora katkı yapan oyuncuların verimlilik puanlarının da yüksek olduğunu göstermektedir.



7) Veri Hazırlama Planı

- **Temizleme:** Takım değiştiren oyuncuların (TOT - Total) kayıtları önceliklendirilmiş veya mükerrer kayıtlar temizlenmiştir. **height** ve **weight** sütunlarındaki eksik veriler temizlenmiştir.
- **Özellik Mühendisliği (Feature Engineering):**
 - Gerçek NBA All-Star listelerine göre oyuncu-sezon eşleştirmesi yapılarak **allstar** (0/1) hedef sütunu oluşturulmuştur.
 - Features (Özellikler): PTS (Sayı), AST (Asist), TRB (Toplam Ribaund), STL (Top Çalma) BLK (Blok) TOV (Top Kaybı) FG%, 3P%, FT% (Şut yüzdeleri) G (Maç Sayısı), MP (Dakika), Year (Dönem kontrolü için)
- **Dönüşümler:** Tüm sayısal özellikler **StandardScaler** ile ölçeklendirilmiştir. Ölçeklendirme özelliikle: **Logistic Regression** (optimizasyon kararlılığı), **PCA** (boyut indirgeme) gibi modellerde performansı artırmak için uygulanmıştır.
- **8) Modelleme Planı**
- **Baseline Model:** Bu projede sınıflandırma için kullanılan **ilk gerçek model** Logistic Regression'dır.

- Bu projede Logistic Regression (baseline), KNN (benzerlik tabanlı), Random Forest (ensemble yöntem), ve SVM (margin tabanlı) olmak üzere dört farklı model ailesi değerlendirilmiş olup, her model All-Star seçimini farklı bir bakış açısıyla tahmin etmektedir.

9) Değerlendirme Tasarımı

- **Doğrulama:** Veri seti %75 Eğitim, %25 Test olarak ayrılmıştır.
- **Metrikler:** ROC–AUC F1 Score Precision Recall Accuracy Confusion Matrix
- **Bulgular:** Bu projede hata analizi Confusion Matrix üzerinden yapılmıştır. TP ve TN değerleri modelin doğru sınıflandırma performansını yansıtırken, FN ve FP değerleri hatalı tahmin türlerini göstermektedir. Özellikle FN (gerçek All-Star'ı kaçırma) kritik bir hata türü olduğu için Recall ve F1 skorları değerlendirmede öncelikli rol oynamıştır.

10) Riskler ve Azaltma Yöntemleri

Veri Sızıntısı (Data Leakage):

- **Veri Dengesizliği:** All-Star sınıfı azınlık olduğu için model çoğunluk sınıfına kayabilir.
- **Veri Kalitesi:** Bazı sezonlarda eksik istatistikler veya çok düşük maç sayısına sahip oyuncular bulunabilir.

Overfitting: Model karmaşılaştıkça eğitim verisine aşırı uyum sağlayıp genel performansı düşürebilir.


- **11) Kullanılan Araçlar**
- **Ortam:** Python 3.x, Jupyter Notebook.
- **Kütüphaneler:** Pandas, NumPy, Sklearn, Matplotlib, Seaborn.

12) Beklenen Sonuçlar ve Görselleştirme Planı


Accuracy : 0.9582
Precision: 0.6357
Recall : 0.7069
F1-score : 0.6694
ROC-AUC : 0.9744

Bu projede kullanılan metrik tablosu, modelin All-Star tahmin performansını özetleyen temel başarı ölçütlerini gösterir. Accuracy modelin genel doğruluğunu, precision modelin “All-Star” dediği oyuncuların ne kadarının gerçekten All-Star olduğunu, recall ise gerçek All-Star oyuncuların ne kadarını tespit edebildiğini ifade eder. F1 skoru precision ve recall arasındaki dengeyi

temsil ederken, ROC-AUC modelin pozitif sınıfı ayırt etme gücünü gösterir ve yüksek değer, güçlü bir ayırıştırma performansına işaret eder.



Karışıklık matrisi modelin hangi sınıfları doğru veya yanlış tahmin ettiğini görselleştirir. Doğru tahmin edilen All-Star olmayan oyuncular ve doğru tahmin edilen All-Star oyuncular matrisin ana başarı bölgesini oluşturur. Yanlış pozitifler modelin gerçekte All-Star olmayan bir oyuncuyu All-Star olarak tahmin ettiği durumları, yanlış negatifler ise modelin gerçek All-Star oyuncularını kaçırdığı durumları temsil eder. Veri dengesizliği nedeniyle yanlış negatiflerin görülmesi olağandır.



ROC eğrisi modelin farklı eşikler altındaki performansını gösterir. Eğrinin sol üst köşeye yakın olması modelin güçlü olduğunu, yüksek AUC değerinin ise All-Star olan ve olmayan oyuncularını oldukça başarılı bir şekilde ayırabildiğini ortaya koyar. Bu grafik modelin genel sınıflandırma yeteneğinin kalitesini gösteren en önemli kanıtlardan biridir.

13) Sonuç (Conclusion)

Bu çalışmada, NBA oyuncularının sezonluk performans istatistiklerine dayanarak All-Star seçilme olasılığını tahmin etmeye yönelik bir sınıflandırma modeli geliştirilmiş ve Logistic Regression başta olmak üzere farklı model ailelerinin karşılaştırılmasıyla en başarılı yaklaşım belirlenmiştir. Uygulanan veri hazırlama, ölçeklendirme, özellik seçimi ve model değerlendirme adımları sonucunda, modellerin All-Star sınıfını ayırt etme performansı ROC-AUC ve F1 skorları üzerinden analiz edilmiş; elde edilen sonuçlar performans istatistiklerinin All-Star seçiminde güçlü belirleyiciler olduğunu göstermiştir. Bu proje, spor analitiği alanında veri madenciliği ve makine öğrenmesi yöntemlerinin etkili biçimde uygulanabileceğini ortaya koyarak başarılı bir tahmine dayalı modelleme örneği sunmuştur.

14) Referanslar

1. **[Veri Seti]** O. Goldstein, "NBA Players stats since 1950," *Kaggle*, 2017. [Çevrimiçi]. Erişim: <https://www.kaggle.com/datasets/drgilermo/nba-players-stats>. [Erişim Tarihi: 24-Kas-2025].
2. **[Makine Öğrenmesi Kütüphanesi - Scikit-learn]** F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, cilt 12, ss. 2825–2830, 2011. [Çevrimiçi]. Erişim: <https://scikit-learn.org/stable/>.
3. **[Veri Analizi Kütüphanesi - Pandas]** W. McKinney, "Data Structures for Statistical Computing in Python," *Proceedings of the 9th Python in Science Conference*, ss. 56–61, 2010.
4. **[Basketbol Analitiği ve Verimlilik]** J. Hollinger, *Pro Basketball Forecast: 2005-06*. Potomac Books, 2005. (PER ve Verimlilik hesaplamaları için temel kaynak).
5. **[Görselleştirme - Matplotlib]** J. D. Hunter, "Matplotlib: A 2D Graphics Environment," *Computing in Science & Engineering*, cilt 9, no. 3, ss. 90–95, 2007.
6. Basketball-Reference, "NBA All-Star Players & Seasons," *Sports Reference LLC*, 2025. Available: <https://www.basketball-reference.com/>